RASL (Retrieval-Augmented Strategy Learning) 研究方案：提升LLM Agent主动学习决策效率（学术版）

摘要

RASL（Retrieval-Augmented Strategy Learning）旨在解决 AAL-SD 中 LLM Agent 的“冷启动低效”问题：在主动学习早期，Agent 缺乏对特定数据集与任务（滑坡语义分割）的先验，容易产生保守或随机策略，从而降低 ALC（Area Under the Learning Curve）。RASL 将“轮级（round-level）主动学习决策”形式化为上下文 bandit / 轮级 MDP：在每轮基于当前状态 s_t 选择动作 a_t（基础动作通常为 λ_t，即不确定性与知识增益的权重），并通过回报 r_t 评估该轮采样对后续性能与稳定性的综合贡献。RASL 的实现形态是“检索增强的 in-context 策略学习”：把历史实验轨迹抽取为（状态、动作、结果/回报）经验三元组存入策略记忆库，通过相似度检索得到可比的成功/失败经验作为上下文，引导 LLM 在当前轮输出更稳健、更可解释的策略。

主要贡献与结论（本任务讨论的要点汇总）

1. 任务对齐：在滑坡语义分割场景中，“采样是否好”必须用端到端收益（如 $\Delta mIoU$、滑坡召回、边界质量、ALC）衡量，不能用单一训练过程信号替代。
2. 指标定位：train_val_cos 适合作为训练健康度/风险信号（惩罚项或约束项），但不是采样优劣的充分指标；仅优化 train_val_cos 会驱动策略过度保守。
3. 奖励设计：推荐 reward 采用“端到端收益 + 过拟合/冲突风险惩罚 +（可选）预算效率”的组合，使策略学习能够识别“收益-风险拐点”，尤其是在后期平台期避免低收益高风险行为。
4. 实证支撑：基于 `/results/logs_md` 的多 seed（42/43/44）轮级曲线，学习曲线形态跨 seed 高度一致，后期边际收益显著降低，为 reward 中加入平台期收缩机制提供经验依据。

1. 研究背景与动机

在AAL-SD（Agent-Assisted Active Learning for Semantic Segmentation）框架的第一阶段研究中，我们发现大型语言模型（LLM）Agent在主动学习的初期阶段，由于缺乏对特定数据集（如Landslide4Sense）的先验知识，往往倾向于采取保守或随机的探索策略。尽管Agent具备强大的推理能力，但这种“冷启动”问题限制了其在有限标注预算下实现最优ALC（Area Under the Learning Curve）

表现。为了克服这一挑战，本研究旨在引入检索增强策略学习（Retrieval-Augmented Strategy Learning, RASL）框架，通过赋予Agent“经验”来显著提升其决策效率和主动学习性能。

2. 核心创新点：RASL 框架

RASL框架的核心思想是通过“检索增强”机制，使LLM Agent能够有效地利用和复用历史实验中积累的成功策略。该框架主要由三个相互协作的组件构成：策略记忆库（Policy Memory Bank）、策略检索器（Policy Retriever）和策略生成器（Policy Generator）。策略记忆库负责存储主动学习过程中积累的“状态-动作-结果”三元组经验。策略检索器则根据当前的学习状态，从记忆库中高效地检索出最相似且表现优异的历史成功案例。最后，策略生成器将检索到的经验作为 In-context Learning 的示例，引导生成更优的λ_t（不确定性与知识增益的权重）。在扩展版本中，也可以把$query_size$与$epochs_per_round$纳入动作空间；但在当前仓库的默认 full_model 配置下，这两者通常由配置固定而非由 Agent 直接控制。**（此为研究提案，非当前实现）**

2.1 形式化问题定义：轮级上下文 bandit / 轮级 MDP

主动学习的轮级过程（round-level active learning）可抽象为“带上下文的序列决策”。

令第 t 轮开始时的系统状态为 s_t，动作 a_t 为本轮的采样/策略选择（基础版本主要为 λ_t），环境转移由一次“采样-标注-训练-评估”闭环定义。定义折扣因子 $\gamma \in (0, 1]$，则目标是最大化期望回报：

$$\max_{\pi} \ \mathbb{E}_{\pi}\Big[\sum_{t=1}^{T} \gamma^{t-1} r_t\Big]$$

在工程实现层面，由于轮级动作对后续多轮表现均有影响，严格建模可视作有限步长 MDP；在经验复用/检索增强的设定下，也可以采用更稳定的“上下文 bandit 近似”，将 r_t 主要定义为“本轮动作对下一轮及其附近窗口”的可观测收益，从而提高经验的可复用性与检索匹配度。

2.2 状态、动作、回报：与滑坡端到端识别对齐

为保证“采样决策 $\rightarrow$ 模型识别质量”的因果对齐，建议将状态拆为四类子状态并拼接为向量或结构化对象：

$$s_t = \big(s_t^{perf},\ s_t^{data},\ s_t^{risk},\ s_t^{ls}\big)$$

- s_t^{perf}：端到端性能与趋势（例如当前 mIoU、$\Delta mIoU$ 及其滑动统计、平台期指示）
- s_t^{data}：未标注池的可采样性分布（例如 $U(x)$、$K(x)$ 的分位数/相关系数、空间聚集度）
- s_t^{risk}：训练健康度/风险（例如轮内后半程的 train_val_cos 汇总、验证曲线波动）
- s_t^{ls}：滑坡任务对齐特征（例如滑坡类召回、滑坡边界质量代理、滑坡像素占比的估计与不确定性）

基础动作空间可定义为：

$$a_t = \lambda_t \in [0, 1]$$

若采用扩展动作空间，可写为 $a_t = (\lambda_t, q_t, e_t)$，其中 q_t 为 query_size，e_t 为每轮训练 epoch；但在本仓库默认 full_model 预算口径下，q_t, e_t 更适合作为常量记录项而非 Agent 直接决策变量。

2.3 理论视角：in-context 策略学习可被视作隐式贝叶斯推断

将“检索到的历史轮级经验”视作上下文 $\mathcal{C}_t = \{(s_i, a_i, r_i)\}_{i=1}^{k}$，则 LLM 在当前轮输出动作 a_t 的过程可解释为：在一个潜在“策略概念” ϕ（例如某一阶段的最优决策规则、风险偏好、或针对数据分布的启发式）上进行后验推断，并据此进行条件决策。该视角与“in-context learning 作为隐式贝叶斯推断”的解释一致：[24]

$$p(\phi \mid \mathcal{C}_t) \propto p(\mathcal{C}_t \mid \phi)\, p(\phi), \quad a_t \sim \pi(\cdot \mid s_t, \phi)$$

进一步地，在“从交互轨迹中进行 in-context 决策/强化学习”的设定中，监督式预训练的序列模型可在上下文中实现近似的后验采样式决策，从而具备“经验 $\rightarrow$ 快速适配”的性质：[25][26] 这为 RASL 的“非参数化策略学习（检索 + ICL）”提供了更直接的理论支撑：我们并不要求在 15 轮内对策略做稳定的梯度更新，而是利用外部经验库把“过去多 run/多 seed 的试错”压缩为可复用的上下文证据链。

3. 关键技术挑战

RASL框架的实现面临多项关键技术挑战。首先是**状态表征（State Representation）问题，即如何将高维的分割模型状态和数据分布（如mIoU趋势、不确定性分布等）有效地转化为可供检索的向量表示，以确保检索的准确性和效率。其次是经验评估（Experience Valuation）**，需要明确定义何为“成功”的经验，例如，是带来最大mIoU增益的决策，还是在特定阶段表现出最佳稳定性的策略。最后是**跨域迁移（Cross-domain Transfer）**的潜力与局限性，即从其他遥感任务（如建筑物提取）中检索到的策略是否能够有效地迁移并应用于滑坡检测任务，这涉及到经验的泛化能力和领域适应性。

4. 预期目标

本研究预期通过RASL框架的引入，实现以下目标：显著缩短主动学习的“冷启动”期，使Agent在早期阶段就能做出高质量决策。在相同的标注预算下，RASL的ALC表现将显著优于纯AAL-SD框架。此外，RASL还将增强Agent决策的可解释性，通过引用历史案例，Agent能够清晰地阐述其决策依据，从而提升整个主动学习过程的透明度和可信度。

5. RASL 框架核心架构设计

RASL 框架将围绕策略记忆库、策略检索器和策略生成器这三个核心组件进行构建，以实现Agent的经验学习和复用。

5.1 策略记忆库 (Policy Memory Bank)

策略记忆库是RASL框架的核心组成部分，用于系统化地存储Agent在主动学习过程中积累的经验。每条经验记录均以一个结构化的三元组（`State, Action, Outcome`）的形式存在。

- **State (状态)**：详细描述决策时的环境信息，包括当前模型在验证集上的 mIoU、F1-score 等性能指标，mIoU 的历史变化趋势（如 miou_delta 及其滑动平均），未标注池中 U(x) 和 K(x) 分数的统计特征及其联合分布，当前已标注样本数量和剩余预算比例，以及当前策略参数（如λ_t）。若扩展动作空间，则可在 State 中附带$query_size/epochs_per_round$等字段用于学习与归因；在默认 full_model 配置下，这些字段更适合作为“配置常量/记录项”而非可决策变量。
- **Action (动作)**：指在特定状态下输出的决策。基础动作可以仅包含λ_t；在扩展版本中可进一步包含$query_size$与$epochs_per_round$等联合动作。
- **Outcome (结果)**：评估该动作执行后对模型性能产生的影响，包括短期收益（下一轮的mIoU增益，即 `miou_delta` ）、长期收益（通过加权或回溯机制评估对最终ALC的贡献），以及训练过程中的稳定性指标（如mIoU波动，即 `sigma_epoch_mIoU` ）。

这些经验将以结构化数据（如JSON格式或数据库记录）的形式存储，并通过提取关键特征（例如，使用Sentence-BERT或其他嵌入模型对State进行编码）作为检索索引，以便后续高效检索。

5.2 策略检索器 (Policy Retriever)

策略检索器负责根据当前学习状态，从策略记忆库中高效地检索出最相关的历史经验。检索过程首先将当前的学习状态转化为向量表示作为**检索查询（Retrieval Query）**。随后，通过**相似度度量（Similarity Metric）**（如余弦相似度）计算当前状态向量与记忆库中所有存储的State向量之间的相似度。检索算法可以采用基于向量相似度的检索技术（如Faiss、Annoy），或探索更复杂的基于图的检索方法。检索到的经验将根据相似度进行排序，并可根据其**Outcome**进行进一步过滤，例如优先检索那些被评估为“成功”的经验。

5.3 策略生成器 (Policy Generator) 与提示词工程 (Prompt Engineering)

策略生成器通过精心的**提示词工程（Prompt Engineering）**，将检索到的历史经验作为上下文信息，引导 LLM Agent 做出更明智的决策。提示词结构将包含：明确 Agent 角色和目标的**系统指令**（如优化 ALC、平衡 U/K），详细描述当前模型性能、数据分布和预算信息的**当前状态描述**，将检索到

的（`State, Action, Outcome`）三元组作为 Few-shot 示例或 In-context Learning 的一部分提供给 Agent 的**检索到的经验**，以及要求基于当前状态和历史经验输出新的决策（基础版本输出λ_t；扩展版本可输出$query_size$、$epochs_per_round$等）并提供决策理由的**决策指令**。通过分析检索到的成功案例，系统能够避免重复历史错误，并借鉴最优实践；决策执行后的结果再回写到策略记忆库中，形成持续演化的闭环。

5.4 检索增强策略学习的数学化描述（Policy as RAG over experience）

将记忆库记为 $\mathcal{M} = \{m_i\}_{i=1}^{N}$，每条经验 $m_i = (s_i, a_i, o_i, r_i)$，其中 o_i 为可选的训练过程摘要（epoch 曲线、回滚事件等），r_i 为标准化回报或多指标 outcome 的压缩表示。

给定当前状态 s_t，检索器定义一个相似度函数 $\mathrm{sim}(\cdot,\cdot)$，返回 Top-$k$ 经验集合：

$$\mathcal{R}(s_t) = \mathrm{TopK}_{m_i \in \mathcal{M}} \, \mathrm{sim}(f(s_t), f(s_i))$$

其中 $f(\cdot)$ 为状态编码器（可为手工特征归一化后的向量，也可为学习到的嵌入）。策略生成器可视作条件分布：

$$\pi(a_t \mid s_t, \mathcal{R}(s_t)) = \mathrm{LLM}\Big(\mathrm{Prompt}(s_t, \mathcal{R}(s_t))\Big)$$

这一定义强调：RASL 并不依赖对 π 的参数化梯度更新，而是通过“经验检索 $\rightarrow$ in-context 泛化”实现快速策略适配；其可解释性来自于 $\mathcal{R}(s_t)$ 中可引用的证据链。

5.5 端到端滑坡识别流程中的 sampling 作用机理

滑坡语义分割中的主动学习采样，其作用机理可被拆为“数据分布重加权 + 难例/边界补齐 + 类别稀缺校正”三条通路：

$$\mathcal{D}_{t+1}^{lab} = \mathcal{D}_t^{lab} \cup \mathcal{Q}_t, \quad \mathcal{Q}_t \subset \mathcal{D}_t^{unlab}, \ |\mathcal{Q}_t| = q_t$$

其中 $\mathcal{Q}_t$ 由 acquisition function 驱动（例如结合不确定性 $U(x)$ 与知识增益 $K(x)$ 的混合评分 $A_\lambda(x) = \lambda U(x) + (1-\lambda)K(x)$）。这一轮样本被标注并加入训练后，更新后的模型 θ_{t+1} 的变化在滑坡任务上主要体现在：

- 对滑坡类稀缺样本的覆盖率提升（提高 R^{ls} 或降低漏检）
- 对边界/破碎区域的拟合能力提升（减少边界错分与碎片化）
- 对域内多样性（地貌、植被、阴影、水体混淆）覆盖更均衡，从而提升泛化

因此，RASL 的 state 与 reward 必须显式包含“滑坡类别与边界质量”的端到端指标或其可计算代理，否则策略会与任务目标脱钩。

5.6 轮级算法流程（概念性）

对第 t 轮，RASL 的闭环可概括为：

1. 用当前模型在未标注池上推理，得到 $U(x), K(x)$ 等统计并构造 s_t。
2. 检索 $\mathcal{R}(s_t)$ 并由 LLM 生成动作 a_t（通常为 λ_t）。
3. 由 a_t 定义 acquisition，对未标注池选择 $\mathcal{Q}_t$，完成标注并训练得到 θ_{t+1}。
4. 在验证/测试集上评估并计算回报 r_t，把 (s_t, a_t, o_t, r_t) 写回 $\mathcal{M}$。

6. 实验方案与评估指标设计

6.1 实验目标

本研究的实验目标主要包括三个方面：首先，**验证RASL的有效性**，旨在证明RASL框架能够显著提升LLM Agent在主动学习中的决策质量，尤其是在冷启动阶段。其次，**量化性能提升**，通过与AAL-SD（无RAG）及其他基线方法进行对比，量化RASL在ALC和最终模型性能上的具体提升。最后，**分析Agent行为**，深入分析Agent在引入RAG后的决策逻辑和策略演变，以验证其“经验复用”的能力和效果。

6.2 实验设置

- **数据集**：为确保与AAL-SD阶段实验结果的可比性，本研究将继续使用Landslide4Sense数据集。
- **模型**：沿用DeepLabV3+ with ResNet50 backbone，保持模型架构的一致性。
- **主动学习协议**：初始标注集、总标注预算和每轮查询大小（$query_size$）将保持与AAL-SD阶段相同，以实现ALC的直接比较。实验轮次也将保持15轮主动学习。
- **基线方法**：本研究将RASL与以下方法进行对比：
  - **AAL-SD (Optimized)**：使用上一阶段优化后的K定义和自适应Rollback阈值的AAL-SD框架作为主要对比基线。
  - **传统基线**：包括Random、Entropy、Core-Set和BALD等经典主动学习策略。
  - **消融实验**：
    - **RASL-No-RAG**：等同于AAL-SD (Optimized)，用于验证RAG模块对性能提升的贡献。
    - **RASL-Random-Retrieval**：RAG模块随机检索经验而非基于相似度，旨在验证检索机制的有效性。
    - **RASL-Fixed-Policy**：Agent仅在冷启动阶段使用RAG检索到的固定策略，之后恢复AAL-SD模式，用于分析RAG对冷启动阶段的影响。

6.3 策略记忆库构建

策略记忆库的构建是RASL框架成功的关键。我们将利用AAL-SD阶段所有实验（包括基线和消融实验）的trace日志，从中提取结构化的 `(State, Action, Outcome)` 三元组。在数据筛选上，将特别关注 `full_model` 和 `fixed_lambda` 等表现良好的实验轨迹，以确保记忆库中经验的质量。在**状态编码**方面，我们将对State中的数值特征进行归一化处理，并可能采用主成分分析（PCA）或自编码器（Autoencoder）等技术进行降维，以便于向量化表示和高效的相似度计算。**经验筛选**将初步筛选出ALC表现优异的实验轨迹中的决策点作为高质量经验，以构建一个精炼且有效的策略记忆库。

6.4 评估指标

本研究将采用以下指标对RASL框架进行全面评估：

1. **主要指标**：
    - **Area Under the Learning Curve (ALC)**：作为衡量主动学习效率的综合指标，其计算方式将与AAL-SD阶段保持一致。
    - **最终mIoU**：在达到总标注预算时，模型在测试集上的mIoU性能。
2. **辅助指标**：
    - **Agent决策质量**：通过分析决策（基础版本为λ_t；如启用扩展动作则包含$query_size$等）与后续 mIoU 增益的相关性，以及评估不同学习阶段策略选择的多样性来衡量。
    - **检索效率**：评估检索器从记忆库中找到“最佳”经验的准确率和召回率。
    - **计算开销**：量化RAG模块引入的额外计算时间开销，以评估其实用性。

6.5 预期结果

我们预期RASL框架将显著提升主动学习的性能。具体而言，RASL有望在ALC和最终mIoU上显著超越AAL-SD (Optimized) 和所有基线方法。尤其是在主动学习的早期阶段（冷启动），RASL将表现出更快的性能增长。此外，我们期望Agent的决策将更具“经验”和“一致性”，减少不必要的探索或保守行为，从而使整个主动学习过程更加稳定和高效。

6.6 `/results` 多 seed 轮级证据（full_model, seeds 42/43/44）

为支撑 reward 设计与“平台期/边际递减”假设，本任务对如下日志文件中每轮“当前轮次最佳结果”的 mIoU 进行了解析汇总：

- `results/logs_md/full_model_20260207_paper_ms_seed42.md`
- `results/logs_md/full_model_20260207_paper_ms_seed43.md`
- `results/logs_md/full_model_20260207_paper_ms_seed44.md`

R1-R15 轮级最佳 mIoU（mean/std 为跨 seed 统计）：

Round	seed42	seed43	seed44	mean	std
1	0.6046	0.6087	0.6646	0.6260	0.0274
2	0.6906	0.7100	0.6796	0.6934	0.0126
3	0.7042	0.7108	0.7210	0.7120	0.0069
4	0.7293	0.7369	0.7269	0.7310	0.0043
5	0.7300	0.7392	0.7383	0.7358	0.0041
6	0.7449	0.7416	0.7413	0.7426	0.0016
7	0.7506	0.7465	0.7423	0.7465	0.0034
8	0.7526	0.7362	0.7528	0.7472	0.0078
9	0.7487	0.7524	0.7523	0.7511	0.0017
10	0.7595	0.7569	0.7514	0.7559	0.0034
11	0.7606	0.7435	0.7508	0.7516	0.0070
12	0.7572	0.7426	0.7413	0.7470	0.0072
13	0.7568	0.7582	0.7578	0.7576	0.0006
14	0.7485	0.7577	0.7545	0.7536	0.0038
15	0.7601	0.7583	0.7500	0.7561	0.0044

从多 seed 证据可得到两条稳定结论：

1. 学习曲线形态高度一致：早期（R1-R6）提升显著，后期（约 R6 之后）进入平台区间，边际收益明显降低。
2. RASL 的 reward 设计需要能“识别并适应平台期”：在低收益区间若继续采取高风险采样/训练配置，将更可能引发不稳定或过拟合而无实质收益。

6.7 train_val_cos 的理论依据、适用性与边界（学术审视）

定义训练与验证损失的梯度分别为 $g_{train} = \nabla_\theta L_{train}(\theta)$、$g_{val} = \nabla_\theta L_{val}(\theta)$，则

$$train_val_cos = \frac{\langle g_{train}, g_{val} \rangle}{\|g_{train}\| \|g_{val}\|}$$

理论合理性要点：

- 在一阶近似下，$train_val_cos < 0$ 表示训练更新方向与验证目标方向冲突。
- 该“负余弦=冲突”的判据与多任务优化中的梯度冲突/对齐框架一致（例如 PCGrad 使用余弦相似度判断冲突并进行投影修正）。类似地，GradNorm 通过动态调节梯度尺度来塑造训练动力学，强调“梯度是训练行为的可控变量”。[5][27]

适用边界要点：

- train_val_cos 是“风险/健康度”信号，而非“收益”信号；因此不应独立作为采样优劣的主指标。
- 在 RASL 中推荐将其用作惩罚项或约束项，并与端到端收益指标共同构成 reward。

进一步地，若希望把“训练健康度”作为硬约束（而非软惩罚），可以采用约束优化的表述：在最大化端到端收益的同时，要求训练-验证梯度对齐不低于阈值 τ（或要求负对齐风险不超过阈值）：

$$\max_{\pi}\ \mathbb{E}_{\pi}\Big[\sum_{t=1}^{T}\gamma^{t-1}\hat{r}_t^{gain}\Big] \quad \text{s.t.} \quad \mathbb{E}_{\pi}\big[c_t^{-}\big] \le \delta$$

其中 $\hat{r}_t^{gain}$ 表示由 $\Delta mIoU$、ΔR^{ls}、ΔB 等构成的收益项，c_t^{-} 由 train_val_cos 派生的风险项。该形式的优点是：在平台期收益天然变小的阶段，策略不会为了追求微小收益而持续“吃掉”风险预算。

6.8 Reward 设计建议（端到端收益 + 风险惩罚 + 可选预算效率）

为避免策略投机（只追求过程指标或只追求短期 mIoU），推荐默认 reward 采用可分解结构：

6.8.1 Outcome $\rightarrow$ 标量回报：窗口化定义与可复现归一化

记第 t 轮训练与评估完成后的轮级端到端指标为：$mIoU_t$、滑坡类召回 R_t^{ls}、边界质量指标 B_t（可取 boundary IoU 或 boundary-F1 等）。定义收益项采用窗口 W 的差分：

$$\Delta_W mIoU_t = mIoU_{t+W} - mIoU_t, \quad \Delta_W R_t^{ls} = R_{t+W}^{ls} - R_t^{ls}, \quad \Delta_W B_t = B_{t+W} - B_t$$

其中 $W = 1$ 对应“本轮决策对下一轮结果”的一阶近邻收益，经验最易复用；若希望降低噪声，可取 $W \in \{2, 3\}$。

为使不同 run、不同阶段的经验可比，推荐对每个指标使用分位数归一化（在线可计算）。给定某个指标序列 $\{z\}$ 在参考集合 $\mathcal{H}_t$ 上的经验分布（例如：同一数据集同一模型的历史经验库；或同 run、同阶段的历史轮集合），记 $Q_p(z;\mathcal{H}_t)$ 为分位数，则：

$$\tilde{z}_t = \mathrm{clip}\left(\frac{z_t - Q_{0.5}(z;\mathcal{H}_t)}{Q_{0.9}(z;\mathcal{H}_t) - Q_{0.1}(z;\mathcal{H}_t) + \epsilon}, -c,\ c\right)$$

其中 $\epsilon > 0$ 防止分母为零，$\mathrm{clip}(\cdot)$ 防止极端离群点主导回报（c 可取 3）。该定义可以直接被复现：只需固定 $\mathcal{H}_t$ 的构造规则与分位数参数。

风险项建议由轮内后半程 train_val_cos 的统计构造。记第 t 轮后半程（例如后 K 个 epoch）的平均为 $\bar{c}_t^{late}$，则：

$$c_t^- = \max(0, -\bar{c}_t^{late}), \quad \tilde{c}_t^- = \mathrm{Norm}(c_t^-)$$

其中 $\mathrm{Norm}(\cdot)$ 可沿用上述分位数归一化。

6.8.2 平台期检测：可核验判据与分段回报

定义轮级增益 $g_t = mIoU_t - mIoU_{t-1}$，用窗口 H 的滑动平均估计边际收益：

$$\bar{g}_t = \frac{1}{H}\sum_{h=0}^{H-1} g_{t-h}$$

给定阈值 $\varepsilon_{gain} > 0$ 与最短持续长度 L，定义平台期指示变量：

$$p_t = \mathbb{I}\Big(\bar{g}_t < \varepsilon_{gain} \ \wedge \ \forall j \in \{0, \dots, L-1\},\ \bar{g}_{t-j} < \varepsilon_{gain}\Big)$$

在平台期（$p_t = 1$）应提高“风险抑制/单位标注收益”的权重，使策略在低收益区间避免高风险行为。一个可复现的分段回报写法为：

$$r_t = \hat{r}_t^{gain} - \big(w_4 + w_4^{plat}\, p_t\big)\, \tilde{c}_t^- + w_5\, p_t \cdot \frac{\Delta_W \tilde{mIoU}_t}{\Delta|\mathcal{D}_t^{lab}| + \epsilon}$$

其中 $\hat{r}_t^{gain} = w_1 \Delta_W \tilde{mIoU}_t + w_2 \Delta_W \tilde{R^{ls}}_t + w_3 \Delta_W \tilde{B}_t$。该机制与多 seed 证据一致：当进入平台区间时，收益项自然变小，分段回报会自动把策略偏好从“强探索”转向“稳健/效率”。

取 $W = 1$ 且不显式引入平台期分段（等价于令 $p_t = 0$）时，上述回报可退化为：

$$r_t = w_1 \Delta_1 \tilde{mIoU}_t + w_2 \Delta_1 \tilde{R^{ls}}_t + w_3 \Delta_1 \tilde{B}_t - w_4 \tilde{c}_t^-$$

该退化形式更接近“单步回报”的上下文 bandit 设定，便于在经验库较小的情况下稳定检索与复用。

6.8.3 梯度动态解耦视角：把“收益-风险-效率”拆成可观测的四维机制

仅用 λ_t 去解释“训练是否稳定/是否高效”往往会混淆多个机制。为让经验可复用、也让策略更可解释，可在不改变主目标（端到端指标）前提下，把训练动力学拆成四类可观测统计，并写入 s_t^{risk}（或单独扩展为 s_t^{grad}）：

- **分布冲击（distribution shock）**：梯度方向在轮间的变化幅度（例如相邻 epoch/轮的梯度余弦差或表示漂移），用于刻画“采样导致的数据分布更新有多剧烈”。
- **收敛速率（convergence rate）**：梯度强度或有效步长代理（例如损失下降斜率、梯度范数的稳态区间），用于刻画“是否在快速学到新信息”。

- **训练稳定性（training stability）**：梯度方向一致性/波动（例如 train_val_cos 的分位数、负对齐事件率），用于刻画“是否出现训练-验证目标冲突与不稳定”。
- **学习效率（learning efficiency）**：单位预算收益（例如 $\Delta_W mIoU$ / 每轮标注量，或 $\Delta_W mIoU$ / 每轮训练开销），用于刻画“是否值得继续高风险/高代价探索”。

该拆分直接对应本项目已有的经验归纳：λ 的调整会同时改变“分布冲击—收敛速率—稳定性—效率”的权衡，因此把这些维度显式写入状态/回报，有助于检索到“机制相似”的历史经验，而不是只做表面指标匹配（例如只看当前 mIoU）。这一点也与前期“梯度动态解耦”材料中对 λ 影响模式的总结一致（见附录 6.11 的对齐清单）。

6.9 学术严谨性审视与验证设计（面向滑坡语义分割）

6.9.1 是否充分考虑滑坡领域 sampling 的数据特性

滑坡遥感分割的采样与识别存在一组稳定的“领域结构”，若不显式建模，AL 策略容易失真：

- 空间自相关与簇状分布：滑坡往往成片出现，同一地貌/地物背景下相邻 patch 高相关，容易导致“批次内重复信息”。
- 类别极不平衡与漏检代价高：滑坡像素占比低、且误检/漏检对灾害任务代价不对称，单纯用整体 mIoU 可能掩盖滑坡类的改善/退化。
- 边界与破碎结构占主导：滑坡边界模糊、碎片化预测常见，采样对“边界/细节”的补齐比对“内部区域”的补齐更关键。
- 难负样本丰富：阴影、水体、裸土、崩塌痕迹等与滑坡外观相近，采样需要覆盖难负样本，避免模型在背景类上过拟合而牺牲滑坡召回。

因此，本方案在 state 与 reward 中显式纳入 s_t^{ls}（滑坡对齐特征）与 $\Delta_W R^{ls}, \Delta_W B$（滑坡召回与边界质量增益），并建议在 s_t^{data} 中增加“空间聚集度/多样性”特征（例如基于 patch 坐标/聚类的覆盖率统计），以对冲空间自相关带来的采样偏置。

6.9.2 Reward 指标设置的合理性（收益-风险可分解）

reward 的合理性取决于它是否满足两点：端到端目标一致性与可稳定估计性。

- 一致性：以 $\Delta_W mIoU$ 作为总体性能收益，以 $\Delta_W R^{ls}$ 与 $\Delta_W B$ 强化滑坡类与边界质量，保证采样决策与灾害识别目标对齐。
- 可估计性：用窗口差分 W 把长期信用分配问题压缩为轮级可观测增量，并通过分位数归一化减少不同 run/阶段的尺度漂移。
- 风险项定位清晰：train_val_cos 派生的 c_t^- 仅作为“训练健康度/冲突风险”惩罚或约束，不取代端到端收益；这避免策略被过程信号劫持而过度保守。

若担心“多指标加权”引入主观性，可在实验中做权重敏感性分析（固定 w_1 为 1，对 w_2, w_3, w_4 做网格/贝叶斯搜索或使用分段约束形式，把风险作为硬约束）。

6.9.3 是否补充了可观测性（避免不可实现的状态/回报）

轮级决策时刻可获得的信息应限定为“在选择 $\mathcal{Q}_t$ 之前可观测”的量：

- 预测侧：未标注池上的 logits/不确定性图、$U(x), K(x)$ 统计、空间聚集度、多样性覆盖率。
- 训练侧：上一轮训练曲线摘要（loss、mIoU 波动）、train_val_cos 的轮内统计、回滚事件等。
- 评估侧：验证/测试集的 $mIoU_t, R_t^{ls}, B_t$（用于构造下一轮的 s_{t+1} 与回报 r_t，而非作为本轮动作的先验）。

严格说，该过程更接近 POMDP：真实“数据分布与可学性”不可完全观测。RASL 的检索增强记忆 $\mathcal{R}(s_t)$ 可以被视作一种“外部记忆/信念补全”，在不引入不可观测变量的前提下提升策略稳健性与可解释性。

6.9.4 实验设计如何验证（因果归因与统计稳健）

建议把验证拆为四类，分别回答“有效吗、为什么、何时有效、代价如何”：

1. 有效性（主结论）：与 AAL-SD（无检索增强）、Entropy、Core-set、BALD、Random 比较 ALC 与最终指标（含滑坡类召回/边界指标），多 seed 报告均值与方差。
2. 机制归因（必要性）：RASL-No-RAG、RASL-Random-Retrieval、只用收益项 vs 收益+风险、是否启用平台期分段 p_t 等消融。
3. 阶段性（何时有效）：按轮分段报告（早期/中期/平台期）的平均增益与风险事件率；验证 RASL 是否主要缩短冷启动，并在平台期降低“低收益高风险”行为。
4. 成本与鲁棒性：报告检索开销（时间/内存）、经验库规模敏感性（用部分历史轨迹构库）、以及训练预算敏感性（例如每轮 5/10/20 epoch 的对照，仅用于验证结论鲁棒，不改变默认口径）。

6.9.5 学术创新性是否足够（相对现有 AL/RAG/RL 的差异点）

本方案的创新性主要来自“把检索增强用于轮级主动学习策略学习”，并针对滑坡分割补齐了可观测 state 与可复现 reward：

- 方法层：以“经验检索 + in-context 策略生成”替代参数化策略梯度更新，在小数据/小回合（15 轮）下更符合可行性与稳定性。
- 目标层：将滑坡任务的类不平衡与边界主导误差显式写入 state/reward，而非仅做通用 mIoU/entropy 驱动。
- 风险层：把 train_val_cos 定位为可解释的风险信号，引入软惩罚或硬约束，使策略在平台期具备“风险预算”概念。
- 证据层：给出多 seed 轮级曲线证据支撑平台期假设，并据此设计分段回报与平台期检测机制。

6.9.6 RASL 是否能在 15 轮、每轮 10 epoch（总 150 epoch）下站住脚

关键点在于：RASL 解决的是“样本选择与策略冷启动”的问题，而不是“把训练算力堆满”。即使总训练 epoch 不大，只要每轮的模型更新能够对采样差异产生可测的端到端响应，策略差异就会累积到 ALC 上。

同时，需要诚实地指出边界：若 10 epoch/轮导致单轮增益噪声过大，信用分配会变难。为此，本方案通过 (i) 窗口化收益 Δ_W（可取 $W = 2/3$ 降噪）、(ii) 分位数归一化、(iii) 平台期分段与风险预算，来提高在“短训练、少回合”条件下的可学习性与可复用性。实验上应通过“训练预算敏感性”对照验证：结论在 5/10/20 epoch/轮下是否保持一致或呈现合理退化。

6.10 相关工作对齐：动态策略、策略学习与 LLM 经验学习

从“为什么需要 RASL”出发，现有工作给出了三类关键启发，但仍留有空缺：

1. **语义分割 AL 的阶段性与策略非万能性**：在语义分割场景中，数据冗余、预算大小、是否采用（半/自）监督预训练会显著改变“哪种 acquisition 更好”，因此不存在跨场景通吃的固定策略；实践上常见“早期更需要多样性覆盖，后期更需要不确定性挖掘”的阶段性切换规律。[10][11][12] 在“目标域标注昂贵”的设定下，也有把主动学习与域适应耦合起来的框架，可作为语义分割场景下的补充参照。[29]
2. **从数据/经验中“学习策略”而非手工指定**：包括把策略选择建模为 bandit（从一组策略中在线挑选）[13]、或直接从历史 AL 过程学习一个“预期误差下降/收益”的回归器或策略模型。[14][15][16] 也存在通过 RL 学习“可迁移的主动学习策略网络”的工作，强调跨图/跨域的策略泛化，与 RASL 的“跨 run/跨数据集经验复用”形成互补参照。[30] 在“动态调参/动态阈值”方向，亦存在用元学习在非平稳流式数据下动态调整主动学习行为的工作，可作为 RASL 的补充参照（但任务形态不同）。[28]
3. **LLM Agent 的经验记忆与语言化强化**：在不更新模型参数的前提下，通过“经验池/记忆 + 自然语言归纳/反思 + 检索回放”提升决策质量，证明了“经验 $\rightarrow$ 知识 $\rightarrow$ 决策”在 Agent 场景的可行性。[17][18] 进一步地，LLM 也被观察到具备从奖励信号进行 in-context 学习的能力，为“非参数化策略学习”提供了更直接的理论与经验依据。[19][20] 与此同时，检索增强也已被用于强化学习以提升样本效率与抗遗忘，提供了“经验库 + 检索器”在决策系统中的另一类实现范式参照。[31]

RASL 的定位与差异点在于：把上述三条线索统一到**轮级主动学习决策**上，并且强制对齐滑坡语义分割的端到端目标与可观测性约束——不直接“让 LLM 选样本”，而是让 LLM 在检索到的可比经验上下文中输出轮级动作（基础形态为 λ_t），并用可复现的窗口化收益、分位数归一化与风险约束来评估经验与回报，从而提升冷启动阶段的决策效率并降低平台期的无效高风险探索。[21][22]

6.11 与前期材料的覆盖度对齐（10 份）

下表用于核验：本研究方案的关键论点/设计均可在前期材料中找到对应依据或批判性约束（内部文档为本仓库材料，便于追溯）。

1. 方法论创新点与差异化定位：见 RASL 方法论创新性查新记录、RASL 方法论学术创新性评价报告；对应本方案第 2/5/6.10 节。
2. 核心学术问题推导（非平稳、少回合、轮级决策）：见 RASL 核心学术问题的深度推导、RASL_ A Theoretical Framework for In-Context Meta-Strategy Learning in Non-Stationary Environments；对应本方案第 2.1/2.3 节。
3. 梯度动力学与“解耦视角”的机制化表达：见 RASL深度研究方案 v2.0：基于梯度动态解耦的视角、RASL_Deep_Research_Proposal_Final_v4；对应本方案第 6.7/6.8.3 节。
4. 文献支撑版需求总结与检索记录（相关工作范围界定）：见 RASL 深度研究方案需求总结（文献支撑版） (1)、RASL 需求总结文献检索记录 (1)；对应本方案第 6.10/参考文献节。
5. 审稿人视角的批判性约束（可实现性、可观测性、归因与消融）：见 RASL 研究方案：审稿人视角下的批判性评估；对应本方案第 6.9 节。
6. 面向滑坡任务的策略迁移与 state/reward 对齐：见 RASL_ Retrieval-Augmented Meta-Strategy Learning for Active Landslide Mapping；对应本方案第 2.2/5.5/6.9.1 节。

7. 参考文献

[1] Settles, B. (2009). *Active Learning Literature Survey*. University of Wisconsin-Madison Technical Report 1648. https://burrsettles.com/pub/settles.activelearning.pdf

[2] Houlsby, N., Huszár, F., Ghahramani, Z., & Lengyel, M. (2011). *Bayesian Active Learning for Classification and Preference Learning*. arXiv:1112.5745. https://arxiv.org/abs/1112.5745

[3] Sener, O., & Savarese, S. (2018). *Active Learning for Convolutional Neural Networks: A Core-Set Approach*. ICLR 2018. arXiv:1708.00489. https://arxiv.org/abs/1708.00489

[4] Xie, B., Yuan, L., Li, S., Liu, C. H., & Cheng, X. (2022). *Towards Fewer Annotations: Active Learning via Region Impurity and Prediction Uncertainty for Domain Adaptive Semantic Segmentation*. CVPR 2022. arXiv:2111.12940. https://arxiv.org/abs/2111.12940

[5] Yu, T., Kumar, S., Gupta, A., Levine, S., Hausman, K., & Finn, C. (2020). *Gradient Surgery for Multi-Task Learning*. NeurIPS 2020. arXiv:2001.06782. https://arxiv.org/abs/2001.06782

[6] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. arXiv:2005.11401. https://arxiv.org/abs/2005.11401

[7] Park, J. S., O’Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). *Generative Agents: Interactive Simulacra of Human Behavior*. UIST 2023. arXiv:2304.03442. https://arxiv.org/abs/2304.03442

[8] Ghorbanzadeh, O., Xu, Y., Ghamisi, P., Kopp, M., & Kreil, D. (2022). *Landslide4Sense: Reference Benchmark Data and Deep Learning Models for Landslide Detection*. arXiv:2206.00515. https://arxiv.org/abs/2206.00515

[9] Landslide4Sense Project Page. https://www.iarai.ac.at/landslide4sense/

[10] Mittal, S., Niemeijer, J., Schäfer, J. P., & Brox, T. (2023). *Best Practices in Active Learning for*

Semantic Segmentation. arXiv:2302.04075. https://arxiv.org/abs/2302.04075
[11] Doucet, P., Estermann, B., Aczel, T., & Wattenhofer, R. (2024). *Bridging Diversity and Uncertainty in Active Learning with Self-Supervised Pre-Training*. arXiv:2403.03728. https://arxiv.org/abs/2403.03728
[12] Hacohen, G., & Weinshall, D. (2023). *How to Select Which Active Learning Strategy is Best Suited for Your Specific Problem and Budget*. NeurIPS 2023. arXiv:2306.03543. https://arxiv.org/abs/2306.03543
[13] Hsu, W.-N., & Lin, H.-T. (2015). *Active Learning by Learning*. AAAI 2015. https://www.semanticscholar.org/paper/Active-Learning-by-Learning-Hsu-Lin/e7e4790b4622d339dcf681ab84c5804551c1b5a3
[14] Konyushkova, K., Sznitman, R., & Fua, P. (2017). *Learning Active Learning from Data*. NeurIPS 2017. arXiv:1703.03365. https://arxiv.org/abs/1703.03365
[15] Fang, M., Li, Y., & Cohn, T. (2017). *Learning how to Active Learn: A Deep Reinforcement Learning Approach*. EMNLP 2017. https://aclanthology.org/D17-1063/
[16] Pang, K., Dong, M., Wu, Y., & Hospedales, T. (2018). *Meta-Learning Transferable Active Learning Policies by Deep Reinforcement Learning*. arXiv:1806.04798. https://arxiv.org/abs/1806.04798
[17] Zhao, A., Huang, D., Xu, Q., Lin, M., Liu, Y.-J., & Huang, G. (2024). *ExpeL: LLM Agents Are Experiential Learners*. AAAI 2024. arXiv:2308.10144. https://arxiv.org/abs/2308.10144
[18] Shinn, N., Labash, B., Gopinath, A., Reddy, A., Elkins, K., Yao, S., & Singh, S. (2023). *Reflexion: Language Agents with Verbal Reinforcement Learning*. NeurIPS 2023. arXiv:2303.11366. https://arxiv.org/abs/2303.11366
[19] Monea, G., Bosselut, A., Brantley, K., & Artzi, Y. (2025). *LLMs Are In-Context Bandit Reinforcement Learners*. COLM 2025. arXiv:2410.05362. https://arxiv.org/abs/2410.05362
[20] Song, K., Moeini, A., Wang, P., Gong, L., Chandra, R., Qi, Y., & Zhang, S. (2025). *Reward Is Enough: LLMs Are In-Context Reinforcement Learners*. arXiv:2506.06303. https://arxiv.org/abs/2506.06303
[21] Arjona-Medina, J. A., Gillhofer, M., Widrich, M., Unterthiner, T., Brandstetter, J., & Hochreiter, S. (2019). *RUDDER: Return Decomposition for Delayed Rewards*. arXiv:1806.07857. https://arxiv.org/abs/1806.07857
[22] Harutyunyan, A., Dabney, W., Mesnard, T., Azar, M. G., Piot, B., Heess, N., van Hasselt, H., Wayne, G., Singh, S., Precup, D., & Munos, R. (2019). *Hindsight Credit Assignment*. NeurIPS 2019. arXiv:1912.02503. https://arxiv.org/abs/1912.02503
[23] Xia, Y., Mukherjee, S., Xie, Z., Wu, J., Li, X., Aponte, R., Lyu, H., Barrow, J., Chen, H., Dernoncourt, F., Kveton, B., Yu, T., Zhang, R., Gu, J., Ahmed, N. K., Wang, Y., Chen, X., Deilamsalehy, H., Kim, S., Hu, Z., Zhao, Y., Lipka, N., Yoon, S., Huang, T.-H. K., Wang, Z., Mathur, P., Pal, S., Mukherjee, K., Zhang, Z., Park, N., Nguyen, T. H., Luo, J., Rossi, R. A., & McAuley, J. (2025). *From Selection to Generation: A Survey of LLM-based Active Learning*. arXiv:2502.11767. https://arxiv.org/abs/2502.11767

[24] Xie, S. M., Raghunathan, A., Liang, P., & Ma, T. (2022). *An Explanation of In-context Learning as Implicit Bayesian Inference*. ICLR 2022. arXiv:2111.02080. https://arxiv.org/abs/2111.02080

[25] Lee, J. N., Xie, A., Pacchiano, A., Chandak, Y., Finn, C., Nachum, O., & Brunskill, E. (2023). *Supervised Pretraining Can Learn In-Context Reinforcement Learning*. NeurIPS 2023. arXiv:2306.14892. https://arxiv.org/abs/2306.14892

[26] Lin, L., Bai, Y., & Mei, S. (2024). *Transformers as Decision Makers: Provable In-Context Reinforcement Learning via Supervised Pretraining*. arXiv:2310.08566. https://arxiv.org/abs/2310.08566

[27] Chen, Z., Badrinarayanan, V., & Lee, C.-Y. (2018). *GradNorm: Gradient Normalization for Adaptive Loss Balancing in Deep Multitask Networks*. ICML 2018. arXiv:1711.02257. https://arxiv.org/abs/1711.02257

[28] Martins, V. E., Cano, A., & Barbon Junior, S. (2023). *Meta-learning for dynamic tuning of active learning on stream classification*. Pattern Recognition, 138, 109359. https://doi.org/10.1016/j.patcog.2023.109359

[29] Wu, T.-H., Liou, Y.-S., Yuan, S.-J., Lee, H.-Y., Chen, T.-I., Huang, K.-C., & Hsu, W. H. (2022). *D2ADA: Dynamic Density-aware Active Domain Adaptation for Semantic Segmentation*. ECCV 2022. arXiv:2202.06484. https://arxiv.org/abs/2202.06484

[30] Hu, S., Xiong, Z., Qu, M., Yuan, X., Côté, M.-A., Liu, Z., & Tang, J. (2020). *Graph Policy Network for Transferable Active Learning on Graphs*. NeurIPS 2020. arXiv:2006.13463. https://arxiv.org/abs/2006.13463

[31] Goyal, A., Friesen, A. L., Banino, A., Weber, T., Ke, N. R., Puigdomenech Badia, A., Guez, A., Mirza, M., Humphreys, P. C., Konyushkova, K., Sifre, L., Valko, M., Osindero, S., Lillicrap, T., Heess, N., & Blundell, C. (2022). *Retrieval-Augmented Reinforcement Learning*. ICML 2022. arXiv:2202.08417. https://arxiv.org/abs/2202.08417